




(b)

图 5MCA 压缩和激励机制

图 5 展示了 MCA 模块通过压缩（Squeeze）和激励（Excitation）两步操作来有效地提取并增强特征信息。首先，压缩阶段通过全局平均池化（AvgPool）和标准差池化（StdPool）对跨维度的特征响应进行聚合，旨在提取全局信息并压缩特征图的空间维度，从而得到更加紧凑的特征表示。该过程有助于捕捉跨空间和通道的全局依赖关系，为后续特征增强提供基础。在激励阶段，模块通过自适应的方式捕捉局部特征的交互，采用轻量化的卷积操作以避免计算开销的增加。这一操作使得模型能够动态调整各通道的权重，有效提升对关键特征的响应能力。通过这两步操作，MCA 模块能够在高效的计算框架下，增强模型对重要特征的表达能力，并有效提高特征的区分性。

基于 RAFT 空间特征提取模块模型如图 6 所示，图中展示了改进后的 RAFT 算法在空间特征提取模块中的流程。首先输入的示踪物体图像经过残差模块提取特征，得到残差模块处理后的特征图，之后通过 MCA 模块进行增强。图中还展示了每个残差模块的内部实现结构，其中包括多个卷积层、ReLU 激活函数和残差连接。其中输入特征 A 首先经过卷积操作实现初步特征提取，生成特征 B，并通过 ReLU 激活函数增强非线性表达能力。之后特征 A 与特征 B 通过逐元素相加实现残差连接，以缓解梯度消失问题并促进信息传递。融合后的特征 C 进一步通过卷积层提取高阶特征，并结合残差连接生成最后的特征 D。




图 6 空间特征提取模块

其中卷积神经网络的卷积结果 $h(u,v)$ 可以表示为(10)式, $f(u-i,v-i)$ 是图像 f 以 (u,v) 为中心的区域, $g(i,j)$ 是卷积核 g 的值。激活函数这里采用 Relu 函数, 表示为(11)形式, 将(10)带入后得到(12)。

$$h(u,v) = (f * g)(u,v) = \sum_{i,j} f(u-i,v-i) \cdot g(i,j) \quad (10)$$

$$Relu(x) = \max(0, x) \quad (11)$$

$$Relu(x) = \max\left(0, \sum_{i,j} f(u-i,v-i) \cdot g(i,j)\right) \quad (12)$$

互关特征提取模块是用来计算连续图像之间的像素级相似性, 最终为光流估计提供丰富的时空特征。其核心思想是通过对连续图像之间的特征进行“互关”(cross-correlation), 在全局范围内高效地捕捉图像的空间和时间依赖关系。实现步骤如图 7 所示。在 RAFT 模型中, 互相关特征提取模块负责提取并计算连续图像之间的时空特征。首先, 模型接收两个输入图像 I_t 和 I_{t+1} 分别表示时间步 t 和 $t+1$ 的图像。然后, 这两个图像通过共享卷积网络进行特征提取, 生成特征图 F_t 和 F_{t+1} 这些特征图捕捉了图像的高维空间信息。最终, 互关操作通过计算 F_t 和 F_{t+1} 之间的相似性来获得两帧图像间的时空依赖性, 可以具体表示为(13)式。




图 7 互相关特征提取模块

$$C(i, j) = \sum_{u, v} F_t(i + u, j + v) \cdot F_{t+1}(u, v) \quad (13)$$

公式(13)中 $C(i, j)$ 表示特征图中每个像素点 (i, j) 处的相似性度量。通过这种方式，模型能够高效地捕捉图像间的动态关系，为后续的光流估计提供准确的时空特征。这一过程为光流计算提供了基础，能够优化模型在处理快速运动和复杂场景时的表现。

3)光流迭代优化单元

在光流迭代优化单元，邻域特征提取步骤如图 8 所示，模型从多尺度的互相关特征图中获取关键信息，捕捉到图像中不同分辨率的时空信息。这个模块的作用是将不同尺度的特征图处理成统一的维度。通过对这些特征图的叠加，最终生成邻域特征图，从而提供更加丰富的空间信息用于后续的光流计算。在邻域特征的提取过程中，关键操作是对每个待求像素点周围的像素进行采样，采样窗口的大小一般由预设的范围来决定。本文在 16×16 的窗口内进行采样，确保模型能够捕捉到较大范围内的邻域信息。在这些邻域像素点中，模型会采集它们的特征信息，并通过这个过程生成一个包含局部上下文的邻域特征。通过这种方式，模型能够充分利用图像中的空间关系，提升光流估计的精度。




图 8 邻域特征提取步骤




图 9 卷积加法自注意力机制模型图

在 RAFT 运动特征提取模块上，原上下文特征根据特征解耦，分为两部分，一部分用于持久化状态（隐藏状态），另一部分用于迭代输入。结合运动特征信息，如果引入自注意力机制，可能会提升模型局部特征提取性能。但是传统的自注意力机制计算复杂度较大，为了显著降低计算复杂度，同时保持全局建模能力，本文引

入 CAS-ViT，图 9 给出了卷积加法自注意力机制的模型图。它结合了空间和通道注意力，通过卷积操作来实现低复杂度的信息交互，并简化了传统的自注意力运算。CAS-ViT 通过卷积与自注意力的深度融合在传统 ViT 基础上实现显著优化。传统的 ViT 由于多头注意力机制导致计算复杂度为 $O(N^2)$ ，而 CAS-ViT 以卷积替代密集交互，将复杂度将至 $O(N)$ 。除此之外，卷积注入的归纳偏置降低对大规模预训练的依赖，能够降低模型的收敛轮数，加快模型的训练速度。




图 10 运动特征提取模块

改进后的 RAFT 运动特征提取模块架构如图 10 所示，其核心创新在于采用上下文特征解耦策略与卷积加法自注意力融合机制。该模块通过解耦局部特征编码与全局相关性建模流程，将卷积操作的局部感知优势与自注意力机制的长程依赖建模能力相结合，实现局部运动细节与全局运动模式的双向协同优化。具体地，卷积分支通过深度可分离卷积高效提取邻域运动特征，而自注意力分支采用加法相似度函数动态捕获跨区域运动关联性，二者通过特征级联与动态权重分配实现互补融合，有效增强多尺度运动特征的代表能力。其中，在自注意力模块 CAS-ViT 中，加性相似度被定义为查询和键在空间中的上下文的和表示为式(14)，通过将 $\Phi(Q)$ 和 $\Phi(K)$ 相加的方式，来模拟它们之间的上下文相关性。 $\Phi(\cdot)$ 是一个映射函数，负责对输入的查询以及键特征图进行处理，以提取空间和通道维度上的上下文信息，这个操作是卷积和池化操作的组合，通过这种方式。避免了传统的矩阵乘法计算，同时增强了